

DOI:10.3969/j.issn.1674-0696.2025.08.14

引文格式:陈丹涌,王俞亮,曾枫泓,等.基于CPSO算法改进GM-Markov模型的港口货物吞吐量预测[J].重庆交通大学学报(自然科学版),2025,44(8):108-115.

Citation:CHEN Danyong, WANG Yuliang, ZENG Fenghong, et al. Port cargo throughput forecasting based on CPSO algorithm improved GM-Markov model[J]. *Journal of Chongqing Jiaotong University (Natural Science)*, 2025, 44(8): 108-115.

基于 CPSO 算法改进 GM-Markov 模型的 港口货物吞吐量预测

陈丹涌¹,王俞亮¹,曾枫泓¹,吴承禧²

(1. 广州航海学院 航运学院,广东 广州 510725;2. 新加坡国立大学 工业系统工程与管理系,新加坡 119077)

摘要:针对广东揭阳港惠来港区货物吞吐量的非线性动态预测需求,提出一种基于混沌粒子群优化的 GM-Markov 组合预测模型。通过集成灰色 GM(1,1)模型与 Markov 链的优势,采用 Logistic 映射实现粒子群参数与状态区间的混沌初始化,构建具有动态适应能力的预测框架;改进后的模型通过状态空间划分与独立概率转移矩阵计算,有效验证了港区 2007—2022 年吞吐量数据的随机波动特征。研究结果表明:优化模型将平均绝对百分比误差下降至 8.06%,较传统方法显著提升了预测精度与稳定性,验证了该模型在动态系统预测中的工程适用性。

关键词:交通运输工程;灰色马尔可夫理论;混沌粒子群优化算法;惠来港区;货物吞吐量预测

中图分类号:U691.71

文献标志码:A

文章编号:1674-0696(2025)08-108-08

Port Cargo Throughput Forecasting Based on CPSO Algorithm Improved GM-Markov Model

CHEN Danyong¹, WANG Yuliang¹, ZENG Fenghong¹, WU Chengxi²

(1. School of Shipping and Maritime Studies, Guangzhou Maritime University, Guangzhou 510725, Guangdong, China;

2. Department of Industrial Systems Engineering and Management, National University of Singapore,

Singapore 119077, Singapore)

Abstract: To address the nonlinear dynamic prediction requirements for cargo throughput in Huilai Port area, Jieyang Port in Guangdong Province, a GM-Markov combined prediction model based on chaotic particle swarm optimization was proposed. By integrating the advantages of the grey GM (1,1) model and Markov chain, Logistic mapping was employed to achieve chaotic initialization of particle swarm parameters and state intervals, and a prediction framework with dynamic adaptability was established. The improved model effectively verified the random fluctuation characteristics of throughput data in the port area from 2007 to 2022 through state space partitioning and independent probability transition matrix calculation. The research results demonstrate that the optimized model reduces the mean absolute percentage error (MAPE) to 8.06%, which significantly enhances the prediction accuracy and stability, compared to traditional methods. The engineering applicability of the proposed model in dynamic system forecasting is also verified.

Key words: traffic and transportation engineering; grey-Markov theory; chaos particle swarm optimization algorithm; Huilai Port area; cargo throughput forecasting

收稿日期:2024-10-08;修订日期:2025-02-28

第一作者:陈丹涌(1972—),男,广东潮州人,副教授,硕士,主要从事交通信息工程与控制方面研究。E-mail:1078876425@qq.com

通信作者:吴承禧(2002—),男,广东揭阳人,硕士研究生,主要从事海事技术与管理方面研究。E-mail:wuchengxi@u.nus.edu

0 引言

广东省惠来县位于粤东新城和揭阳滨海新区,是粤东地区重要的对外贸易门户。得益于发达的海上运输业,近年来揭阳港的惠来港区在基础设施建设、功能布局优化和业务范围拓展方面取得了显著成效,货物吞吐量稳步增长。港口货物吞吐量不仅反映了港口运输能力和经济发展水平,也是港口投资决策、资源配置和市场竞争的重要参考。港口吞吐量受社会经济发展情况等诸多因素影响,其中某些影响因素之间的内在联系并不明确,可视为一种灰色系统。

目前,针对港口货物吞吐量的预测主要分为两类:基于时间序列的方法(如指数平滑法、自回归移动平均法)和基于因素分析的方法(如多元线性回归法、神经网络法)。此外,诸如基于机器学习的集成方法(如随机森林、XGBoost)和基于深度学习的长短期记忆网络(LSTM)及混合模型(如 ARIMA-LSTM 组合模型)也逐步被引入到货物吞吐量的预测中,这些方法在处理复杂非线性和长时间序列预测时各有优缺点,也存在一定局限性^[1]。封钰等^[2]通过随机森林算法和粗糙集理论的改进型深度学习短期负荷预测模型,在提高预测精度方面表现良好。但对特征选择的依赖性较强,缺乏动态适应机制;杨宇鸽等^[3]将 Neural-Prophet 模型与 LSTM 相结合,通过对残差进行修正,显著提升了吞吐量预测精度,但该模型依赖外部数据完整性,若缺失或不可靠,则会影响预测效果;丁天明等^[4]基于灰色 GM(1,1)模型与 Markov 模型,通过引入粒子群算法优化状态区间,提升了预测精度和稳定性,但在处理复杂非线性问题时仍可能会陷入局部最优,且状态区间划分固定,缺乏动态调整能力。

笔者基于 Markov 模型,对 GM(1,1)模型预测值进行修正和优化,再采用 CPSO 算法对粒子数量及各状态区间进行 Logistic 映射初始化,增强了算法全局搜索能力,同时可有效地避免陷入局部最优解,使得该模型能根据实际情况对每个状态区间进行独立分析和计算,得到了较高精度的吞吐量预测值,为港口未来规划提供一定参考。

1 港口条件与吞吐量数据

1.1 惠来港区基本情况

惠来县是揭阳市唯一的临海辖县,沿海岸线长

111.53 km,拥有 1 328.6 km² 的海域面积。惠来港区北邻汕头港,西南毗邻甲子港,东南面临南海,沿海港口主要由神泉、靖海、前詹、仙庵、南海作业区构成,该海域具有水域面积广阔、波浪较小、回淤量小、水深条件优越,地质条件好等特点。该港区地处粤东地理和海陆空交通中心,是广东省重要的港口之一,其主要承担着粤东地区煤炭、石油、化工、建材等大宗货物的进出口运输任务,对于揭阳市建设广东新型工业化城市、海上风电运维基地、重要石化能源基地及临海特色产业战略高地具有强有力的支撑作用。

1.2 惠来港区货物吞吐量基础数据

根据《揭阳港总体规划(2035 年)》,2007—2022 年惠来港区的吞吐量如表 1。由表 1 可知:惠来港区的货物吞吐量在这十年间呈现出波动增长趋势,具有一定的随机性和动态性。

表 1 惠来港区吞吐量(2007—2022)
Table 1 Cargo throughput of Huilai Port area (2007—2022)

年份	吞吐量/万吨	年份	吞吐量/万吨
2007	112	2015	534
2008	187	2016	482
2009	210	2017	644
2010	297	2018	696
2011	407	2019	718
2012	303	2020	700
2013	628	2021	1 112
2014	594	2022	1 341

2 改进 GM-Markov 模型

2.1 灰色预测模型

GM(1,1)模型是基于灰色系统理论的一阶单变量微分方程预测模型。利用原始数据序列的累加生成新的数据序列,然后通过建立微分方程来描述新序列的变化规律,并基于最小二乘法估计方程参数,得到所需要的预测模型。作为微分方程模型的离散形式,该模型可用于时间序列的预测^[5]。

GM(1,1)模型的数学表达式为^[6]:设原始数据序列为 $Z^{(0)} = \{z^{(0)}(1), z^{(0)}(2), \dots, z^{(0)}(n)\}$,其中: $z^{(0)}(k)$ 为第 k 个观测值, n 为样本个数。

对原始数据序列进行一次累加处理,从而生成一个新的数据序列,如式(1)。

$$Z^{(1)} = \{z^{(1)}(1), z^{(1)}(2), \dots, z^{(1)}(n)\} \quad (1)$$

建立 GM(1,1)模型如式(2):

$$\frac{dz^{(1)}}{dt} + az^{(1)} = b \quad (2)$$

式中: a 、 b 分别为待估参数,反映了系统发展的速度和灰色作用。

设初始条件为 $z^{(1)}(0) = z^{(0)}(1)$, 则微分方程的解为:

$$\hat{z}^{(1)}(k+1) = \left(z^{(0)}(1) - \frac{b}{a} \right) e^{-ak} + \frac{b}{a} \quad (3)$$

式中: $\hat{z}^{(1)}$ 为预测值; e 为自然对数底数。

利用最小二乘法对 a 、 b 进行求解^[7], 如式(4):

$$\hat{\alpha} = [a, b]^T = (B^T B)^{-1} B^T Y_n$$

$$B = \begin{bmatrix} -\frac{1}{2}[z^{(1)}(1) + z^{(1)}(2)] & 1 \\ \vdots & \vdots \\ -\frac{1}{2}[z^{(1)}(k-1) + z^{(1)}(k)] & 1 \end{bmatrix}$$

$$Y_n = \begin{bmatrix} z^{(0)}(2) \\ \vdots \\ z^{(0)}(n) \end{bmatrix} \quad (4)$$

式中: B 表示第1列为背景值序列,第2列为常数项的矩阵; Y_n 表示原始序列从第2项至第 n 项的列向量。

将 a 、 b 代入,即可求得一阶累加序列的预测值;再对预测值进行累减处理,以恢复原始数据序列预测结果 $\hat{z}^{(0)} = \{\hat{z}^{(0)}\}$, 其中: $\hat{z}^{(0)} = \hat{z}^{(1)} - \hat{z}^{(-1)}$, $k = 2, 3, \dots, n$ 。

2.2 Markov 模型修正

Markov 是基于概率的数学模型,描述了系统在不同状态之间的随机转移过程。Markov 模型核心特征在于,系统的下一个状态仅由当前状态决定,与之前的历史状态无关。可根据系统历史数据计算出不同状态之间的转移概率,然后根据 Markov 理论求解出系统的稳态概率分布,从而得到系统未来状态的最优预测值。该方法克服了传统预测方法的局限,比如灰色预测模型在处理波动性和非线性数据时存在一定误差。

Markov 模型优化 GM(1, 1) 模型的预测结果,其步骤为:

1) 将原始数据序列输入 GM(1, 1) 模型,获得预测结果和相应的残差值^[8], 如式(5)。

$$\delta(i) = z^{(0)}(i) - \hat{z}^{(0)}(i) \quad (i = 1, 2, \dots, n) \quad (5)$$

式中: $\delta(i)$ 为第 i 项的预测残差(误差值)。

2) 将残差值划分为 m 个状态区间: $[e_1, f_1)$,

$[e_2, f_2), \dots, [e_m, f_m)$ 。状态区间划分原则是使得每个状态区间内的数据尽可能均匀分布,同时使不同状态区间之间的差异尽可能明显。

3) 将残差值转换为不同的状态序列 T_k , 对应不同的状态区间。比如:若第 k 个残差值落在第某个状态区间内,则有 $T_k = q$ 。

4) 根据 T_k 计算每个等级之间的状态转移概率矩阵 $P = (p_{qg})_{m \times n}$, 表示从第 q 个等级转移到第 g 个等级的概率。其计算如式(6):

$$p_{qg} = n_{qg} / n_q \quad (6)$$

式中: n_{qg} 为状态序列中从第 q 个等级转移到第 g 个等级的次数; n_q 为状态序列中出现第 q 个等级次数。

则转移概率矩阵 P 如式(7):

$$P = \begin{bmatrix} P_{11} & P_{12} & \cdots & P_{1n} \\ P_{21} & P_{22} & \cdots & P_{2n} \\ \vdots & \vdots & \vdots & \vdots \\ P_{n1} & P_{n2} & \cdots & P_{nn} \end{bmatrix} \quad (7)$$

5) 借助 Markov 模型对预测结果进行修正。取当前状态区间上、下限平均值进行运算,得出最终的灰色 Markov 模型,如式(8):

$$\tilde{z}^{(0)}(k) = \frac{\hat{z}^{(0)}(k)}{1 + 0.5(e_g + f_g)} \quad (8)$$

式中: $\tilde{z}^{(0)}(k)$ 为灰色马尔可夫预测结果; $\hat{z}^{(0)}(k)$ 为灰色预测结果; e_g 为状态区间的下限; f_g 为状态区间的上限。

基于 Markov 模型,能够对 GM(1, 1) 模型的预测结果进行修正和提高,使其更加贴近实际的变化规律和趋势。

2.3 混沌粒子群优化 GM-Markov 模型

PSO 算法(particle swarm optimization)模拟了鸟群、鱼群等动物的社会行为特征,通过个体和群体的历史最佳位置来更新粒子速度和位置,以寻找问题的最优解。该方法以较少的参变量、强大的全局搜索能力和快速的收敛速度而著称。 o 个粒子组合成一个群集,在 u 维空间中,每个粒子 i 都对应一个 U 维向量,每个向量都代表着一个白化因子 β_i , 每个粒子 i 在空间里以速度 V_{id} 进行搜索,搜索位置 X_{id} 和速度 V_{id} 不断地更新迭代^[9]。其表达如式(9):

$$V_{id}^{k+1} = wV_{id}^{k+1} + c_1r_1(p_{id} - X_{id}^k) + c_2r_2(g_{id} - X_{id}^k)$$

$$X_{id}^{k+1} = X_{id}^k + V_{id}^{k+1} \quad (9)$$

式中: V_{id}^k 表示第 i 个粒子在第 k 次迭代中第 d 个维度上的速度; X_{id}^k 表示第 i 个粒子在第 k 次迭代中第

d 个维度上的位置; w 为惯性权重,用于平衡全局搜索与局部搜索能力; c_1 、 c_2 分别为学习因子(加速常数),分别代表个体和群体经验影响程度; r_1 、 $r_2 \in [0,1]$,均为服从均匀分布的随机数; p_{id} 为粒子个体历史最优位置; g_{id} 为全体粒子的全局最优位置。

假定灰色预测区间的状态为 I_i ,将 β_i 带入上述状态区间,如式(10):

$$I_i = \beta_i e_g + f_g(1 - \beta_i) \quad (10)$$

式中: β_i 为加权系数,用于调节全局与局部信息的贡献比例。

每个粒子性能优劣由适应度函数来衡量,而适应度函数则由残差平方均值指标 R 来确定,其值越小,表明粒子的性能越佳^[10]。粒子适应度函数的表达如式(11):

$$R = \frac{1}{n} \sum_{i=1}^n \varepsilon_i^2 \quad (11)$$

式中: ε_i 为第 i 个样本点的残差,即实际值与预测值之差。

普通粒子群算法虽能较好地对模型进一步优化,但其应对复杂问题存在容易过早收敛、陷入局部极值点、缺乏有效局部搜索机制等缺陷,使得该算法的预测效果无法达到最优。因此,笔者引进混沌粒子群算法(CPSO 算法)对每个状态 I 的参数因子进行优化。利用混沌运动的遍历性,以当前粒子群搜索到的最优位置为基础,生成一个混沌序列,从该混沌序列中选择最优位置粒子,随机替换当前粒子群中的某个粒子位置,从而提升原有粒子群的优化效率进而求解最优的状态区间值^[11]。CPSO 算法优化步骤为:

1) 利用混沌搜索机制搜寻最优粒子。根据混沌变量的随机性、遍历性及规律性,使得其成为优化搜索过程中的一种有效工具^[12],该算法通过跳出局部最优来寻找更优化的粒子。

Logistic 映射是混沌理论和复杂系统中广泛应用的非线性迭代公式,其通用形式为:

$$z_{k+1} = rz_k(1 - z_k), k = 0, 1, 2, \dots \quad (12)$$

式中: z_k 表示在第 k 次迭代时的状态变量; r 表示控制参数。

r 决定了系统行为特性,包括周期性、混沌性等。通常 $r=2.00$, 3.57 , 4.00 , r 取不同值所对应的系统行为如下:当 $r=2.00$ 时,系统进入稳定状态,数值在迭代过程中会收敛到某个定值;当 $r=3.57$ 时,系统开始进入混沌状态,这时的迭代过程不再稳定,混沌

系统表现出对初始条件的极端敏感性,即便微小的初始变化,也会导致结果显著不同;当 $r=4.00$ 时,系统处于完全混沌状态,每次迭代后的值会在 $[0, 1]$ 区间内呈高度不规则分布。

2) 寻找适合的惯性权重因子 ω ,如式(13)。 ω 在 CPSO 算法中起到至关重要作用,能平衡全局搜索与局部搜索的能力。若 ω 较大时,能增强算法的全局搜索能力,使其能更好地探索空间;若 ω 较小时,有利于局部搜索,使算法能更加精细地调整。故在迭代中采用线性递减的 ω 能使得算法在初期具备强大的全局搜索能力,从而迅速找到接近全局最优解的区域,在后期则增强了局部搜索能力,以提高最终优化精度^[13]。

$$\omega = \omega_{\max} - \frac{m(\omega_{\max} - \omega_{\min})}{M} \quad (13)$$

式中: ω 为当前迭代的惯性权重,用于控制粒子当前速度对下次更新的影响程度; $\omega_{\max}$ 为惯性权重最大值; $\omega_{\min}$ 为惯性权重最小值; m 为当前进化的迭代次数; M 为最大进化的迭代次数。

3) 寻找适合的学习因子 c 。认知因子 c_1 代表粒子对自身经验的依赖程度,可增强局部搜索能力;社会因子 c_2 代表粒子对群体经验的依赖水平,可增强全局搜索能力。 c 能在 CPSO 算法中进行自适应调节,以提高算法性能。笔者在迭代过程中采用线性递增和递减相结合策略,使其在前半段迭代中逐渐变化,在后半段迭代中则反向变化,这样能有效调整粒子在搜索初期和后期的探索和开发行为,以达到更加出色的全局和局部搜索能力^[14]。

迭代前半段(全局搜索阶段):

当 $m \leq M/2$ 时,粒子群的学习因子逐渐增大,从而增强了粒子对自身经验和群体经验依赖,促进全局搜索,如式(14):

$$\begin{cases} c_1 = c_1 + (2 - c_1) \times \frac{m}{M/2} \\ c_2 = c_2 + (2 - c_2) \times \frac{m}{M/2} \end{cases} \quad (14)$$

迭代后半段(局部搜索阶段):

当 $m > M/2$ 时,粒子逐渐减少对群体经验依赖,更多地依赖自身经验,从而增强了局部搜索能力,如式(15):

$$\begin{cases} c_1 = c_1 - (c_1 - 1) \times \frac{m - M/2}{M/2} \\ c_2 = c_2 - (c_2 - 1) \times \frac{m - M/2}{M/2} \end{cases} \quad (15)$$

2.4 后验差计算

笔者对所提出的3种模型进行误差和后验差检验;对基于CPSO优化的Markov模型的预测结果有效性进行评估;对这3种模型修正结果进行综合评估^[15]。

残差均值如式(16):

$$\bar{\varepsilon}^{(0)} = \frac{1}{n} \sum_{i=1}^n \varepsilon^{(0)} i \quad (16)$$

式中: $\varepsilon^{(0)}$ 为残差数列。

残差方差如式(17):

$$S_1^2 = \frac{1}{n} \sum_{i=1}^n (\varepsilon^{(0)} - \bar{\varepsilon}^{(0)})^2 \quad (17)$$

式中: S_1^2 为原始残差序列的方差。

原始数据均值如式(18):

$$\bar{z} = \frac{1}{n} \sum_{i=1}^n z_i^{(0)} \quad (18)$$

式中: $z^{(0)}$ 表示原始数据序列的平均值。

原始数据方差如式(19):

$$S_2^2 = \frac{1}{n} \sum_{i=1}^n (z_i^{(0)} - \bar{z})^2 \quad (19)$$

式中: S_2^2 为原始数据 $z^{(0)}$ 的方差。

后验差比值 v 如式(20):

$$v = \frac{S_1}{S_2} \quad (20)$$

误差概率 p 如式(21):

$$p = \{0.6745 S_2 > |\varepsilon_i^{(0)} - \bar{\varepsilon}^{(0)}|\} \quad (21)$$

式中:0.6745是正态分布中误差绝对值小于标准差一半时的概率系数。

将得到的后验差比值与误差概率分为4个等级,如表2。

表2 精度等级分级

Table 2 Accuracy level classification

精度等级	v	p
1	<0.35	>0.95
2	<0.50	>0.80
3	<0.65	>0.70
4	≥0.65	≤0.70

3 实例分析

3.1 GM(1,1)模型预测

笔者将各年吞吐量进行排列,整理出原始数据数列: $z^{(0)} = \{112, 187, 210, 297, 407, 303, 628,$

594, 534, 482, 644, 696, 718, 700, 1 112, 1 341\}。将 $z^{(0)}$ 中的数据累加得到数据序列: $z^{(1)} = \{112, 299, 509, 806, 1 213, 1 516, 2 144, 2 740, 3 274, 3 756, 4 400, 5 096, 5 814, 6 514, 7 626, 8 967\}$ 。

代入式(3),得到: $a = -0.114 9; b = 205.307 9$ 。

故解为: $\hat{z}^{(1)}(k+1) = 1 898.202 8 e^{0.114 9k} - 1 786.202 8$ 。

3.2 GM-Markov 模型预测

笔者将GM(1,1)模型预测结果整理为预测值数列: $\hat{z}^{(0)} = (112.00, 231.22, 259.38, 290.97, 326.42, 366.18, 410.78, 460.81, 516.94, 579.91, 650.55, 729.79, 818.68, 918.41, 1 030.27, 1 155.77)$ 。将 $z^{(0)}$ 与 $\hat{z}^{(0)}$ 代入式(5),可得残差数列: $\varepsilon = (0, -44.22, -49.38, 6.03, 80.59, -63.18, 217.22, 135.19, 17.06, -97.91, -6.55, -33.79, -100.68, -218.41, 81.73, 185.23)$ 。

根据残差数列将残差值的状态划分为5个区间,如表3。

表3 状态区间划分

Table 3 State interval partitioning

残差状态区间	范围
高估(S_1)	$[-218.405 4, -131.279 8)$
较高估(S_2)	$[-131.279 8, -44.154 3)$
较准确(S_3)	$[-44.154 3, 42.971 3)$
较低估(S_4)	$[42.971 3, 130.096 8)$
低估(S_5)	$[130.096 8, 217.222 4]$

根据式(6)、式(7)建立状态转移矩阵 P ,如式(22):

$$P =$$

$$\begin{bmatrix} 0.280 0 & 0.080 0 & 0.280 0 & 0.280 0 & 0.080 0 \\ 0.133 3 & 0.133 3 & 0.133 3 & 0.133 3 & 0.466 7 \\ 0.240 0 & 0.140 0 & 0.540 0 & 0.040 0 & 0.040 0 \\ 0.100 0 & 0.100 0 & 0.350 0 & 0.100 0 & 0.350 0 \\ 0.133 3 & 0.133 3 & 0.133 3 & 0.466 7 & 0.133 3 \end{bmatrix} \quad (22)$$

将 P 和划分区间代入式(9),就可得灰色Markov模型的预测结果: $\tilde{z}^{(0)} = (112, 243.65, 271.82, 303.41, 338.86, 378.61, 589.48, 571.49, 529.38, 592.35, 504.55, 742.23, 831.12, 772.41, 884.27, 1 168.21)$ 。

由于原始数据波动性较大,GM(1,1)模型无法准确捕捉数据波动特征,导致结果存在较大误差。为改进预测效果,笔者在 GM(1,1)模型预测结果与原始数据差值基础上,建立了灰色 Markov 模型。利用 Markov 模型对离散随机波动数据的处理能力,对预测误差进行修正,提高了预测值与实际值的吻合度,提升了预测精度^[16]。

3.3 GM-Markov-CPSO 模型预测

传统的灰色 Markov 组合模型各区间的白化系数取中间值,实际上其最优状态并不是中间值,笔者利用粒子群算法迭代搜寻各状态区间的实际参数,确定当下合适的白化因子^[17],步骤如图 1。




图 1 CPSO 具体步骤
Fig. 1 CPSO specific steps

1) 将划分的 5 个残差状态区间视为灰色系统的状态区间,将各状态区间白化系数作为输入,代入 PSO 算法,用来优化灰色系统模型参数^[18]。经多次调试,取参数最大种群数为 50,粒子长度为 5,学习因子 $c_1 = 2, c_2 = 2$,迭代次数为 200,最小惯性权重 $w_{\min} = 0.4$,最大惯性权重 $w_{\max} = 0.9$,当粒子最小为 0 时,最大更新位置为 1;当粒子最小为 -0.02 时,最大更新速度为 0.02。

2) 对粒子数及每个状态区间进行 Logistic 映射初始化,为确保初始粒子位置具有高度多样性和混沌性,增强算法的全局搜索能力及提升摆脱局部最优解能力,笔者选择 $r = 4$ 的控制参数,生成混沌序列即初始粒子,如图 2。




图 2 Logistic 映射初始粒子位置
Fig. 2 Logistic mapping of initial particle positions

3) 调整惯性权重和学习因子使其自适应,利用 CPSO 算法得到优化区间白化系数 $\lambda = [0.689\ 9, 0.704\ 9, 0.705\ 0, 0.999\ 0, 0.999\ 7]$ 。与 GM-Markov 模型对比发现其拟合度更高,将优化后的 λ 值分别应用于 GM-Markov 预测模型中的各个状态区间,得到改进后的预测结果。这 3 种模型 2007—2022 年的预测值如表 4。

表 4 3 种模型预测吞吐量预测值对比

Table 4 Comparison of throughput prediction values by the three kinds of models

年份	实际	预测			万吨
		GM(1,1)	GM-Markov	GM-Markov-CPSO	
2007	112	112.00	112.00	120.77	
2008	187	231.21	243.65	239.99	
2009	210	259.38	271.82	268.15	
2010	297	290.97	303.41	299.74	
2011	407	326.42	338.85	335.19	
2012	303	366.17	378.61	320.40	
2013	628	410.78	589.48	589.42	
2014	594	460.81	571.49	571.37	
2015	534	516.94	529.38	525.71	
2016	482	579.91	592.35	479.18	
2017	644	650.55	504.55	659.32	
2018	696	729.79	742.23	738.56	
2019	718	818.68	831.12	717.95	
2020	700	918.41	772.40	817.68	
2021	1 112	1 030.27	884.27	1 140.83	
2022	1 341	1 155.77	1 168.21	1 334.41	

3.4 预测结果比较

笔者将这 3 种拟合模型的预测值数据分别进行对比,如图 3。




图3 这3种模型的预测值与实际情况对比


Fig. 3 Comparison between the predicted values by the three kinds of models and actual situation

由图3可知:随着年份推移,这3种模型的预测值越来越贴近实际值,其中GM-Markov-CPSO模型预测值最接近于实际值,表明该模型的优化水平最高。

3.5 GM-Markov-CPSO模型预测性能

3.5.1 平均绝对百分比误差

平均绝对百分比误差(E_{MAP})是一项重要的评价指标。在对比这3种模型的预测性能时,通过计算预测值与实际值间绝对误差占实际值的比例,可直观地反映出预测精度^[19],如图4。

图4 这3种模型的 E_{MAP} Fig. 4 E_{MAP} for the three kinds of models

E_{MAP} 的计算如式(23):

$$E_{\text{MAP}} = \frac{1}{n} \sum_{i=1}^n \left| \frac{z_i - \hat{z}_i}{z_i} \right| \times 100\% \quad (23)$$

GM-Markov-CPSO模型的 $E_{\text{MAP}} = 8.06\%$,显著低于GM(1,1)模型的15.18%和GM-Markov模型的14.09%。这表明GM-Markov-CPSO模型进一步优化了模型参数并修正了状态,显著降低了预测误差,

验证了其在预测中的优越性能。

3.5.2 精度分析

笔者对这3种模型进行误差和后验差检验,如表5。由表5可知:这3种模型的精度等级均为一级;相较于GM(1,1)模型,GM-Markov模型的精度有所提高;GM-Markov-CPSO模型的 c 值最小,精度最优,相较于前两者模型,其 E_{MAP} 下降至8.06%,这也说明经过二次修正后的模型拟合度更高,更贴合实际^[20]。

表5 这3种模型的精度对比

Table 5 Comparison of accuracy of the three kinds of models

预测模型	参数		精度等级
	p	c	
GM(1,1)	1	0.1176	1级
GM-Markov	1	0.0946	1级
GM-Markov-CPSO	1	0.0190	1级

3.6 港区未来4年港口货物吞吐量预测

由此可得到2023—2026年惠来港区的港口货物吞吐量预测值,如表6。

表6 港口货物吞吐量预测(2023—2026)

Table 6 Port cargo throughput forecasting (2023—2026)

年份	预测值/万吨	年份	预测值/万吨
2023	1 296.55	2025	1 631.65
2024	1 454.48	2026	1 830.39

4 结论

笔者运用CPSO优化算法对GM-Markov模型进行了优化,并对惠来港区的港口货物吞吐量进行了预测,得出如下结论:

1) GM-Markov模型通过结合GM(1,1)模型与Markov模型,显著改善了预测模型在处理波动性数据时的局限性;通过Markov模型修正数据残差,使得预测的精度和稳定性表现出显著提升。

2) 改进后的CPSO-GM-Markov模型在惠来港区货物吞吐量预测中展现出更优的效果。通过优化普通PSO算法的局部搜索能力,克服了其易陷入局部极值点和过早收敛的缺陷,同时对状态区间参数选择进行优化,显著降低了预测残差均值。

3) 笔者以惠来港区的吞吐量历史值作为样本数据,暂未考虑可能影响港口货物吞吐量的其他因素(如经济环境、政策变化、市场需求等),在以后研究中拟引入更多相关变量,尝试采用多元回归或神经网络等模型进行预测,进一步提升预测效果。

参考文献 (References):

- [1] 孙志林, 卢雅倩, 黄赛花. 港口吞吐量的马氏链-时序分析预测[J]. 浙江大学学报(工学版), 2012, 46(7): 1289-1294.
SUN Zhilin, LU Yaqian, HUANG Saihua. Prediction of port throughput based on Markov chain-time series analysis[J]. *Journal of Zhejiang University (Engineering Science)*, 2012, 46(7): 1289-1294.
- [2] 封钰, 宋佑斌, 金晟, 等. 基于随机森林算法和粗糙集理论的改进型深度学习短期负荷预测模型[J]. 发电技术, 2023, 44(6): 889-895.
FENG Yu, SONG Yubin, JIN Sheng, et al. Improved deep learning short-term load forecasting model based on random forest algorithm and rough set theory[J]. *Power Generation Technology*, 2023, 44(6): 889-895.
- [3] 杨宇鸽, 郝杨杨, 王逸文. 基于 Neural Prophet-LSTM 组合模型的港口货物吞吐量预测[J]. 中国航海, 2023, 46(4): 85-92.
YANG Yuge, HAO Yangyang, WANG Yiwen. Prediction of port cargo throughput using Neural Prophet-LSTM combination model[J]. *Navigation of China*, 2023, 46(4): 85-92.
- [4] 丁天明, 潘宁, 杜柏松, 等. 基于改进灰色马尔可夫的港口货物吞吐量预测研究[J]. 重庆交通大学学报(自然科学版), 2023, 42(9): 130-136.
DING Tianming, PAN Ning, DU Baisong, et al. Forecast of cargo throughput in port based on improved grey Markov[J]. *Journal of Chongqing Jiaotong University (Natural Science)*, 2023, 42(9): 130-136.
- [5] 刘思峰, 郭天榜. 灰色系统理论及其应用[M]. 2版. 北京: 科学出版社, 1999.
LIU Sifeng, GUO Tianbang. *Grey System Theory and Its Application* [M]. 2nd ed. Beijing: Science Press, 1999.
- [6] 杨金宝, 梁勇, 曹现宪. 一种基于灰色理论-隐马尔科夫模型的装备故障预测方法[J]. 舰船电子工程, 2018, 38(8): 128-132.
YANG Jinbao, LIANG Yong, CAO Xianxian. A method of equipment failure prediction based on grey theory-HMM[J]. *Ship Electronic Engineering*, 2018, 38(8): 128-132.
- [7] 徐志胜. 安全系统工程[M]. 北京: 机械工业出版社, 2007.
XU Zhisheng. *Safety System Engineering* [M]. Beijing: China Machine Press, 2007.
- [8] SHAMSHAD A, BAWADI M A, WANHUSSIN W M A, et al. First and second order Markov chain models for synthetic generation of wind speed time series[J]. *Energy*, 2005, 30(5): 693-708.
- [9] 杨承莲, 徐厚宝. 基于粒子群优化灰色马尔可夫模型及其应用[J]. 数学的实践与认识, 2023, 53(9): 267-276.
YANG Chenglian, XU Houbao. Grey Markov model optimized by particle swarm algorithm and application[J]. *Mathematics in Practice and Theory*, 2023, 53(9): 267-276.
- [10] 马全党, 江福才, 范庆波, 等. PSO-无偏灰色马尔科夫模型在船舶交通流量预测中的应用[J]. 中国航海, 2019, 42(1): 97-103.
MA Quandang, JIANG Fucui, FAN Qingbo, et al. Application of PSO-unbiased grey Markov model in ship traffic flow prediction[J]. *Navigation of China*, 2019, 42(1): 97-103.
- [11] 李兵, 蒋慰孙. 混沌优化方法及其应用[J]. 控制理论与应用, 1997, 14(4): 613-615.
LI Bing, JIANG Weisun. Chaos optimization method and its application[J]. *Control Theory & Applications*, 1997, 14(4): 613-615.
- [12] 吴月秋, 纪昌明, 王丽萍, 等. 基于混沌粒子群算法的水电站水库优化调度[J]. 人民黄河, 2008, 30(11): 96-97.
WU Yueqiu, JI Changming, WANG Liping, et al. Optimal operation of hydropower stations and reservoirs based on chaotic particle swarm optimization algorithm[J]. *Yellow River*, 2008, 30(11): 96-97.
- [13] 高尚, 杨静宇. 混沌粒子群优化算法研究[J]. 模式识别与人工智能, 2006, 19(2): 266-270.
GAO Shang, YANG Jingyu. Research on chaos particle swarm optimization algorithm[J]. *Pattern Recognition and Artificial Intelligence*, 2006, 19(2): 266-270.
- [14] 高鹰, 谢胜利. 混沌粒子群优化算法[J]. 计算机科学, 2004, 31(8): 13-15.
GAO Ying, XIE Shengli. Chaos particle swarm optimization algorithm[J]. *Computer Science*, 2004, 31(8): 13-15.
- [15] CHEN Yakuan, GOLDSMITH J, OGDEN R T. Variable selection in function-on-scalar regression[J]. *Stat*, 2016, 5(1): 88-101.
- [16] LI Zhijun, WANG Weiwei, CHEN Mianyun. Improved grey-Markov chain algorithm for forecasting[J]. *Kybernetes*, 2009, 38(3/4): 329-338.
- [17] HU Hongtao, ZHAI Xiaojing, GUAN Xin. Crude oil output forecasting based on PSO of unbiased gray Markov model[C]// 2017 8th IEEE International Conference on Software Engineering and Service Science (ICSESS). 2017, Beijing, China. IEEE, 2017: 644-647.
- [18] 朱红求, 阳春华, 桂卫华, 等. 一种带混沌变异的粒子群优化算法[J]. 计算机科学, 2010, 37(3): 215-217.
ZHU Hongqiu, YANG Chunhua, GUI Weihua, et al. Particle swarm optimization with chaotic mutation[J]. *Computer Science*, 2010, 37(3): 215-217.
- [19] POLLOCK A C, MACAULAY A, DILEK Ö A, et al. Evaluating predictive performance of judgmental extrapolations from simulated currency series[J]. *European Journal of Operational Research*, 1999, 114(2): 281-293.
- [20] AGRAWAL S, SILAKARI S, AGRAWAL J. Adaptive particle swarm optimizer with varying acceleration coefficients for finding the most stable conformer of small molecules[J]. *Molecular Informatics*, 2015, 34(11/12): 725-735.

(责任编辑:刘 韬)